



دانشکده مهندسی برق و کامپیوتر
گروه مهندسی کامپیوتر

عنوان:

ارزیابی عملکرد طبقه‌بند k -نزدیک‌ترین همسایه برای طبقه‌بندی تصاویر با استفاده از
اعتبارسنجی متقابل

استاد محترم:

دکتر مریم شعاران

دانشجو:

امیررضا میرزاجانی اسکوئی

مرداد ۱۴۰۴

نام خانوادگی دانشجو: میرزاجانی اسکوئی		نام: امیررضا	
عنوان: ارزیابی عملکرد طبقه‌بند k-نزدیک‌ترین همسایه برای طبقه‌بندی تصاویر با استفاده از اعتبارسنجی متقابل			
استاد محترم: دکتر مریم شعاران			
مقطع تحصیلی: کارشناسی ارشد		رشته: مهندسی مکانیک	
دانشگاه: تبریز		گرایش: طراحی کاربردی	
دانشکده: مهندسی مکانیک		تعداد صفحات: ۱۳	
کلیدواژه‌ها: k-نزدیک‌ترین همسایه، طبقه‌بندی تصاویر، CIFAR-۱۰، یادگیری ماشین، اعتبارسنجی متقابل، بهینه‌سازی هایپرپارامتر.			
چکیده: طبقه‌بندی تصاویر یکی از مسائل محوری در حوزه بینایی ماشین است. در این پژوهش، الگوریتم غیرپارامتری k-نزدیک‌ترین همسایه (kNN) به منظور طبقه‌بندی مجموعه داده استاندارد CIFAR-۱۰ پیاده‌سازی و ارزیابی شده است. هدف اصلی این پروژه، بررسی عملکرد این طبقه‌بند و تحلیل تأثیر حجم داده‌های آموزشی بر انتخاب بهینه هایپرپارامتر k می‌باشد. به این منظور، ابتدا آزمایش‌ها بر روی یک زیرمجموعه کوچک شامل ۵۰۰ نمونه آموزشی و سپس بر روی یک مجموعه بزرگتر شامل ۵۰۰۰ نمونه آموزشی انجام گردید. برای یافتن مقدار بهینه k در هر آزمایش، از روش اعتبارسنجی متقابل ۵-بخشی استفاده شد. نتایج نشان داد که با افزایش حجم داده‌های آموزشی، مقدار بهینه k از ۱ به ۱۰ افزایش یافت که بیانگر قابلیت مدل برای استفاده از اطلاعات همسایه‌های بیشتر به منظور دستیابی به یک طبقه‌بندی قوی‌تر است. مدل نهایی که با k بهینه و بر روی ۵۰۰۰ نمونه آموزشی، آموزش دید، توانست به دقت نهایی ۲۸.۲٪ بر روی مجموعه داده تست دست یابد. این پژوهش، کارایی طبقه‌بند kNN را تأیید کرده و اهمیت فرآیند اعتبارسنجی متقابل و تأثیر حجم داده بر بهینه‌سازی هایپرپارامترها را به وضوح نشان می‌دهد.			

۱- مقدمه

طبقه‌بندی تصاویر به عنوان یکی از مسائل بنیادی در حوزه بینایی ماشین و هوش مصنوعی، کاربردهای گسترده‌ای از تشخیص چهره تا خودروهای خودران را در بر می‌گیرد. الگوریتم‌های متنوعی برای حل این مسئله توسعه یافته‌اند که هر کدام دارای نقاط قوت و ضعف خود هستند. یکی از الگوریتم‌های کلاسیک، قلیل فهم و در عین حال قدرتمند در این زمینه، طبقه‌بند k -نزدیک‌ترین همسایه^۲ است. این الگوریتم غیرپارامتری، بر پایه این ایده ساده استوار است که یک نمونه داده جدید، به کلاسی تعلق دارد که بیشترین همسایگان آن در فضای ویژگی به آن کلاس تعلق دارند.

هدف اصلی از این پروژه، پیاده‌سازی کامل و تحلیل عملکرد طبقه‌بند k NN بر روی مجموعه داده استاندارد CIFAR-۱۰^۳ است. در این راستا، ابتدا داده‌ها بارگذاری، پیش‌پردازش و به دو مجموعه آموزشی و تست تقسیم می‌شوند. سپس، برای یافتن مقدار بهینه هایپرپارامتر k ، از روش اعتبارسنجی متقابل ۵-بخشی^۴ استفاده می‌گردد. در نهایت، مدل با k بهینه بر روی کل داده‌های آموزشی، آموزش داده شده و عملکرد نهایی آن بر روی داده‌های تست که تا به حال مشاهده نکرده، ارزیابی می‌شود. این گزارش، مراحل پیاده‌سازی، تحلیل نتایج و نتیجه‌گیری نهایی از عملکرد مدل را به تفصیل شرح خواهد داد.

۲- روش شناسی

در این بخش، مجموعه داده مورد استفاده و الگوریتم‌های به کار رفته برای پیاده‌سازی و ارزیابی طبقه‌بند k -نزدیک‌ترین همسایه به تفصیل شرح داده می‌شوند.

۲-۱ مجموعه داده CIFAR-۱۰

مجموعه داده CIFAR-۱۰ یکی از دیتاست‌های استاندارد و پرکاربرد در حوزه بینایی ماشین برای ارزیابی الگوریتم‌های طبقه‌بندی تصاویر است. این مجموعه داده شامل ۶۰,۰۰۰ تصویر رنگی با ابعاد کوچک 32×32 پیکسل می‌باشد. این تصاویر به ۱۰ کلاس مجزا تقسیم‌بندی شده‌اند که هر کلاس شامل ۶,۰۰۰ تصویر است. کلاس‌ها عبارتند از: هواپیما، اتومبیل، پرنده، گربه، گوزن، سگ، قورباغه، اسب، کشتی و کامیون. کل مجموعه داده به دو بخش اصلی تقسیم شده است: ۵۰,۰۰۰ تصویر برای مجموعه آموزشی^۴ و ۱۰,۰۰۰ تصویر برای مجموعه تست^۵ که امکان آموزش و ارزیابی مدل را فراهم می‌آورد.

پس از معرفی مشخصات کلی مجموعه داده CIFAR-۱۰، در شکل ۱ نمونه‌هایی از تصاویر موجود در هر یک از ده کلاس نمایش داده شده است. همانطور که مشاهده می‌شود، این تصاویر با ابعاد کوچک 32×32 پیکسل، چالش‌های قابل توجهی را برای طبقه‌بندی به همراه دارند. تنوع بالا در زاویه دید، شرایط نوری، پس‌زمینه و موقعیت اشیاء در تصاویر، پیچیدگی مسئله را افزایش می‌دهد. هدف از نمایش این نمونه‌ها، ارائه


^۲ k-Nearest Neighbor - kNN

^۳ ۱۰-Fold Cross-Validation

^۴ training set

^۵ test set

یک درک بصری از ماهیت داده‌هایی است که طبقه‌بند k -NN باید بر اساس آن‌ها آموزش دیده و ارزیابی شود.



شکل ۱- نمونه تصاویر از مجموعه داده CIFAR-۱۰

۲-۲ طبقه‌بند k -نزدیک‌ترین همسایه (k NN)

الگوریتم k -نزدیک‌ترین همسایه (k NN) یک روش یادگیری نظارت‌شده ساده و در عین حال قدرتمند است که بر اساس اصل شباهت عمل می‌کند. این الگوریتم به دلیل ماهیت غیرپارامتری خود، یک طبقه‌بند تنبل^۶ محسوب می‌شود، زیرا فرآیند یادگیری پیچیده‌ای ندارد. عملکرد این الگوریتم در دو مرحله اصلی خلاصه می‌شود:

- ✓ **مرحله آموزش:** در این مرحله، طبقه‌بند به سادگی تمام داده‌های آموزشی و لیبل‌های مربوط به آن‌ها را در حافظه خود ذخیره می‌کند. هیچ مدل ریاضیاتی در این مرحله ساخته نمی‌شود.
- ✓ **مرحله تست (پیش‌بینی):** برای طبقه‌بندی یک نمونه داده جدید و دیده‌نشده، الگوریتم فاصله آن را (معمولاً فاصله اقلیدسی) با تمام نمونه‌های موجود در مجموعه آموزشی محاسبه می‌کند. سپس، k نمونه آموزشی را که کمترین فاصله را با نمونه جدید دارند، به عنوان «نزدیک‌ترین همسایه‌ها» انتخاب می‌کند. در نهایت، با شمارش لیبل‌های این k همسایه، کلاسی که بیشترین تکرار را داشته باشد، به عنوان کلاس نمونه جدید پیش‌بینی می‌شود.

۲-۲ اعتبارسنجی متقابل (Cross-Validation)

^۶ Lazy Learner

انتخاب مقدار بهینه برای هایپرپارامتر k ، تأثیر مستقیمی بر عملکرد طبقه‌بند kNN دارد. یک k بسیار کوچک می‌تواند منجر به حساسیت بیش از حد به نویز و بیش‌برازش^۷ شود، در حالی که یک k بسیار بزرگ ممکن است مرز بین کلاس‌ها را بیش از حد ساده کرده و منجر به کم‌برازش^۸ شود. به منظور یافتن مقدار بهینه k و جلوگیری از بیش‌برازش، در این پروژه از روش اعتبارسنجی متقابل ۵-بخشی استفاده شده است. در این روش، مجموعه داده آموزشی به ۵ بخش مساوی تقسیم می‌شود. سپس فرآیند آموزش ۵ بار تکرار می‌گردد؛ در هر تکرار، ۴ بخش برای آموزش مدل و ۱ بخش باقی‌مانده برای ارزیابی (اعتبارسنجی) آن به کار می‌رود. در نهایت، میانگین دقت‌های به دست آمده از این ۵ مرحله، به عنوان یک تخمین قابل اعتماد از عملکرد مدل برای آن k خاص در نظر گرفته می‌شود. این فرآیند برای تمام مقادیر k مورد نظر تکرار شده و k که بالاترین میانگین دقت را داشته باشد، به عنوان مقدار بهینه انتخاب می‌گردد.

۳- نتایج

در این بخش، نتایج حاصل از پیاده‌سازی طبقه‌بند k -نزدیک‌ترین همسایه بر روی زیرمجموعه‌هایی از دیتاست CIFAR-۱۰ ارائه و تحلیل می‌شود. آزمایش‌ها در دو مرحله، ابتدا با یک مجموعه داده کوچک برای ارزیابی اولیه و سپس با یک مجموعه بزرگتر برای کسب نتایج قابل اعتمادتر، انجام شده است.

۳-۱- آزمایش اولیه با مجموعه داده کوچک

به منظور بررسی اولیه عملکرد الگوریتم و تسریع فرآیند اعتبارسنجی متقابل، ابتدا یک زیرمجموعه کوچک از داده‌ها شامل ۵۰۰ نمونه آموزشی و ۵۰ نمونه تست انتخاب گردید. جدول ۱ نتایج دقت خام به دست آمده از این پنج مرحله را برای هر مقدار k نمایش می‌دهد. همانطور که مشاهده می‌شود، برای هر k ، پنج مقدار دقت متفاوت ثبت شده است که هر کدام مربوط به یکی از پنج مرحله اعتبارسنجی می‌باشند. وجود پراکندگی در این مقادیر، نشان‌دهنده حساسیت عملکرد مدل به داده‌های آموزشی مختلف است.

جدول ۱- دقت‌های خام به دست آمده از ارزیابی طبقه‌بند

kNN در هر یک از پنج بخش اعتبارسنجی متقابل (۵۰

نمونه تست و ۵۰۰ نمونه آموزش)

k	Accuracy
۱	۰.۲۴۰۰۰۰
۱	۰.۲۳۰۰۰۰
۱	۰.۲۴۰۰۰۰
۱	۰.۲۵۰۰۰۰
۱	۰.۲۹۰۰۰۰
۳	۰.۱۷۰۰۰۰
۳	۰.۲۵۰۰۰۰

^۷ Overfitting

^۸ Underfitting

۳	.۱۷۰۰۰۰
۳	.۱۸۰۰۰۰
۳	.۳۰۰۰۰۰
۵	.۱۹۰۰۰۰
۵	.۲۱۰۰۰۰
۵	.۱۷۰۰۰۰
۵	.۲۰۰۰۰۰
۵	.۲۵۰۰۰۰
۸	.۲۱۰۰۰۰
۸	.۲۲۰۰۰۰
۸	.۱۹۰۰۰۰
۸	.۱۹۰۰۰۰
۸	.۲۵۰۰۰۰
۱۰	.۲۲۰۰۰۰
۱۰	.۱۷۰۰۰۰
۱۰	.۱۹۰۰۰۰
۱۰	.۲۲۰۰۰۰
۱۰	.۲۳۰۰۰۰
۱۲	.۲۱۰۰۰۰
۱۲	.۱۹۰۰۰۰
۱۲	.۱۹۰۰۰۰
۱۲	.۲۱۰۰۰۰
۱۲	.۲۷۰۰۰۰
۱۵	.۱۹۰۰۰۰
۱۵	.۱۸۰۰۰۰
۱۵	.۲۳۰۰۰۰
۱۵	.۲۱۰۰۰۰
۱۵	.۲۳۰۰۰۰
۲۰	.۱۴۰۰۰۰
۲۰	.۲۲۰۰۰۰
۲۰	.۲۰۰۰۰۰
۲۰	.۲۳۰۰۰۰
۲۰	.۲۶۰۰۰۰
۵۰	.۱۵۰۰۰۰
۵۰	.۱۶۰۰۰۰
۵۰	.۲۳۰۰۰۰
۵۰	.۲۱۰۰۰۰
۵۰	.۲۸۰۰۰۰
۱۰۰	.۱۴۰۰۰۰
۱۰۰	.۱۴۰۰۰۰
۱۰۰	.۲۴۰۰۰۰
۱۰۰	.۲۱۰۰۰۰
۱۰۰	.۲۵۰۰۰۰

به منظور نتیجه‌گیری نهایی و انتخاب یک مقدار بهینه برای k ، در بخش بعدی این نتایج خام با محاسبه میانگین و انحراف معیار، خلاصه‌سازی و تحلیل شده‌اند که در جدول ۲ آورده شده است.

جدول ۲- میانگین دقت حاصل از اعتبارسنجی متقابل ۵-
بخشی برای مقادیر مختلف هایپرپارامتر k (۵۰ نمونه تست
و ۵۰۰ نمونه آموزش)

k	Accuracy
۱	۰.۲۵۰۰
۳	۰.۲۱۴۰
۵	۰.۲۰۴۰
۸	۰.۲۱۲۰
۱۰	۰.۲۰۶۰
۱۲	۰.۲۱۴۰
۱۵	۰.۲۰۸۰
۲۰	۰.۲۱۰۰
۵۰	۰.۲۰۶۰
۱۰۰	۰.۱۹۶۰


همانطور که در جدول و نمودار مشخص است، بیشترین میانگین دقت (۰.۲۵۰۰) در مقدار $k=1$ به دست آمده است. با افزایش مقدار k ، میانگین دقت به طور کلی کاهش می‌یابد که نشان می‌دهد برای این مجموعه داده، استفاده از نزدیک‌ترین همسایه به تنهایی بهترین عملکرد را دارد. نکته قابل توجه، افزایش انحراف معیار در مقادیر بالاتر k است که نشان‌دهنده حساسیت بیشتر مدل به داده‌های آموزشی مختلف در آن حالت‌ها می‌باشد. با توجه به این نتایج، مقدار $k=1$ به عنوان پارامتر بهینه برای آموزش مدل نهایی انتخاب گردید. در نهایت، مدل با $k=1$ بر روی کل مجموعه آموزشی، آموزش داده شد و بر روی مجموعه تست ارزیابی گردید که به دقت نهایی ۰.۲۶۰۰ دست یافت. نزدیکی دقت تست نهایی به میانگین دقت اعتبارسنجی، نشان‌دهنده قابلیت تعمیم‌پذیری خوب مدل و عدم وقوع بیش‌برازش است.

نمودار واقع در شکل ۲، ماتریس فاصله اقلیدسی محاسبه شده بین ۵۰ نمونه داده تست (محور عمودی) و ۵۰۰ نمونه داده آموزشی (محور افقی) را به صورت یک نقشه حرارتی^۹ نمایش می‌دهد. در این نمایش، رنگ هر پیکسل نشان‌دهنده میزان شباهت بین یک جفت تصویر تست و آموزشی است؛ رنگ‌های تیره‌تر به معنای فاصله کمتر و شباهت بصری بیشتر، و رنگ‌های روشن‌تر به معنای فاصله بیشتر و شباهت کمتر می‌باشند. مشاهده الگوهای نواری عمودی در این ماتریس، نشان‌دهنده وجود برخی نمونه‌های آموزشی است که به تعداد زیادی از تصاویر تست شباهت دارند و به عنوان «نمونه‌های اولیه»^{۱۰} در فضای ویژگی عمل می‌کنند. در مقابل، سطرها عمدتاً روشن، بیانگر تصاویر تست آتیپیک هستند که به سختی با نمونه‌های آموزشی موجود مطابقت داده می‌شوند و احتمال طبقه‌بندی اشتباه آن‌ها بالاست. این تجسم، اساس عملکرد طبقه‌بند k -NN را که بر

^۹ heatmap


^{۱۰} prototypes

پایه یافتن نزدیک‌ترین همسایه‌ها در این ماتریس استوار است، به خوبی به تصویر می‌کشد و درک کیفی از ساختار و پراکندگی داده‌ها را فراهم می‌آورد.



شکل ۲- تجسم ماتریس فاصله برای طبقه‌بند k -NN بین ۵۰۰ نمونه آموزشی و ۵۰ نمونه تست

شکل ۳ نتایج حاصل از فرآیند اعتبارسنجی متقابل ۵-بخشی را به منظور انتخاب مقدار بهینه هایپرپارامتر k برای طبقه‌بند k -نزدیک‌ترین همسایه نمایش می‌دهد. محور افقی مقادیر مختلف k مورد آزمایش و محور عمودی، دقت طبقه‌بندی را نشان می‌دهد.



شکل ۳- نتایج اعتبارسنجی متقابل برای بهینه‌سازی هایپرپارامتر k (۵۰ نمونه تست و ۵۰۰ نمونه آموزشی)

در این نمودار، هر نقطه رنگی مجزا، دقت به دست آمده در یکی از پنج مرحله اعتبارسنجی را برای یک k مشخص نشان می‌دهد. خط آبی یکپارچه، میانگین این پنج دقت را به هم متصل کرده و روند کلی عملکرد مدل را با تغییر k به تصویر می‌کشد. نوارهای خطای عمودی نیز بیانگر انحراف معیار نتایج هستند که پراکندگی و پایداری عملکرد مدل را برای هر k نشان می‌دهند؛ نوارهای کوتاه‌تر به معنای عملکرد پایدارتر است. با تحلیل نمودار، مشاهده می‌شود که بیشترین میانگین دقت در مقادیر پایین k (در این نمودار به نظر می‌رسد در بازه $k=1$ تا $k=8$) به دست آمده است. با افزایش k به مقادیر بسیار بزرگتر، میانگین دقت به تدریج کاهش می‌یابد. این پدیده نشان می‌دهد که با در نظر گرفتن تعداد زیادی از همسایه‌ها، مدل شروع به ساده‌سازی بیش از حد مرزهای تصمیم‌گیری کرده و دچار Underfitting می‌شود. بر اساس این تحلیل، مقدار k که به بالاترین نقطه روی خط روند میانگین دست یافته است، به عنوان مقدار بهینه برای آموزش مدل نهایی انتخاب می‌گردد تا بهترین قابلیت تعمیم‌پذیری بر روی داده‌های جدید را داشته باشد.

۳-۲- آزمایش اولیه با مجموعه داده کوچک

پس از بررسی اولیه، به منظور ارزیابی دقیق‌تر و قابل اعتمادتری از عملکرد طبقه‌بند، آزمایش با مجموعه داده بزرگتری شامل ۵۰۰۰ نمونه آموزشی و ۵۰۰ نمونه تست تکرار گردید که نتایج کامل این آزمایش در جدول ۳ و ۴ و همچنین شکل‌های ۴ و ۵ ارائه شده است.

جدول ۳- دقت‌های خام به دست آمده از ارزیابی طبقه‌بند

kNN در هر یک از پنج بخش اعتبارسنجی متقابل (۵۰۰)

(نمونه تست و ۵۰۰۰ نمونه آموزش)

k	Accuracy
۱	۰٫۲۶۳۰۰۰
۱	۰٫۲۵۷۰۰۰
۱	۰٫۲۶۴۰۰۰
۱	۰٫۲۷۸۰۰۰
۱	۰٫۲۶۶۰۰۰
۳	۰٫۲۳۹۰۰۰
۳	۰٫۲۴۹۰۰۰
۳	۰٫۲۴۰۰۰۰
۳	۰٫۲۶۶۰۰۰
۳	۰٫۲۵۴۰۰۰
۵	۰٫۲۴۸۰۰۰
۵	۰٫۲۶۶۰۰۰
۵	۰٫۲۸۰۰۰۰
۵	۰٫۲۹۲۰۰۰
۵	۰٫۲۸۰۰۰۰
۸	۰٫۲۶۲۰۰۰
۸	۰٫۲۸۲۰۰۰
۸	۰٫۲۷۳۰۰۰
۸	۰٫۲۹۰۰۰۰


۸	۰,۲۷۳۰۰۰
۱۰	۰,۲۶۵۰۰۰
۱۰	۰,۲۹۶۰۰۰
۱۰	۰,۲۷۶۰۰۰
۱۰	۰,۲۸۴۰۰۰
۱۰	۰,۲۸۰۰۰۰
۱۲	۰,۲۶۰۰۰۰
۱۲	۰,۲۹۵۰۰۰
۱۲	۰,۲۷۹۰۰۰
۱۲	۰,۲۸۳۰۰۰
۱۲	۰,۲۸۰۰۰۰
۱۵	۰,۲۵۲۰۰۰
۱۵	۰,۲۸۹۰۰۰
۱۵	۰,۲۷۸۰۰۰
۱۵	۰,۲۸۲۰۰۰
۱۵	۰,۲۷۴۰۰۰
۲۰	۰,۲۷۰۰۰۰
۲۰	۰,۲۷۹۰۰۰
۲۰	۰,۲۷۹۰۰۰
۲۰	۰,۲۸۲۰۰۰
۲۰	۰,۲۸۵۰۰۰
۵۰	۰,۲۷۱۰۰۰
۵۰	۰,۲۸۸۰۰۰
۵۰	۰,۲۷۸۰۰۰
۵۰	۰,۲۶۹۰۰۰
۵۰	۰,۲۶۶۰۰۰
۱۰۰	۰,۲۵۶۰۰۰
۱۰۰	۰,۲۷۰۰۰۰
۱۰۰	۰,۲۷۰۰۰۰
۱۰۰	۰,۲۵۶۰۰۰
۱۰۰	۰,۲۶۳۰۰۰

جدول ۴- میانگین دقت حاصل از اعتبارسنجی متقابل ۵-
بخشی برای مقادیر مختلف هایپرپارامتر k (۵۰۰ نمونه تست
و ۵۰۰۰ نمونه آموزش)


k	Accuracy
۱	۰.۲۶۵۶
۳	۰.۲۴۹۶
۵	۰.۲۷۳۲
۸	۰.۲۷۶۰
۱۰	۰.۲۸۰۲
۱۲	۰.۲۷۹۴
۱۵	۰.۲۷۵۰

۲۰	۰.۲۷۹۰
۵۰	۰.۲۷۴۴
۱۰۰	۰.۲۶۱۶

مدل نهایی که با استفاده از $k=10$ و بر روی کل ۵۰۰۰ نمونه آموزشی، آموزش داده شد، در ارزیابی نهایی بر روی مجموعه تست به دقت ۲۸.۲٪ دست یافت (۱۴۱ پاسخ صحیح از ۵۰۰). این دقت، که بر اساس یک ارزیابی جامع‌تر به دست آمده است، تخمین معتبرتری از عملکرد واقعی طبقه‌بند k -NN بر روی مجموعه داده CIFAR-۱۰ ارائه می‌دهد و بهبود عملکرد ناشی از افزایش داده‌های آموزشی و انتخاب صحیح هایپرپارامتر را به وضوح نشان می‌دهد.



شکل ۴- تجسم ماتریس فاصله برای طبقه‌بند k -NN بین ۵۰۰۰ نمونه آموزشی و ۵۰۰ نمونه تست



شکل ۵- نتایج اعتبارسنجی متقابل برای بهینه‌سازی هایپرپارامتر k (۵۰۰۰ نمونه آموزشی و ۵۰۰ نمونه تست)

با افزایش حجم داده‌های آموزشی، مشاهده می‌شود که مقدار بهینه هایپرپارامتر k از $k=1$ (که در مجموعه داده کوچک به دست آمده بود) به $k=10$ تغییر یافت. این پدیده نشان می‌دهد که با وجود داده‌های بیشتر، مدل قادر است از اطلاعات همسایه‌های بیشتری برای یک طبقه‌بندی قوی‌تر و با قابلیت تعمیم بالاتر، بهره‌برد.

۴- نتیجه‌گیری

در این پروژه، طبقه‌بند k -نزدیک‌ترین همسایه (kNN) به منظور حل مسئله طبقه‌بندی تصاویر، با موفقیت پیاده‌سازی و ارزیابی گردید. فرآیند کار شامل مراحل کلیدی بارگذاری و پیش‌پردازش مجموعه داده استاندارد CIFAR-۱۰، پیاده‌سازی الگوریتم kNN با رویکردهای مختلف محاسبه فاصله و بهینه‌سازی هایپرپارامتر k با استفاده از روش اعتبارسنجی متقابل ۵-بخشی بود.

نتایج آزمایش‌ها دو یافته کلیدی را آشکار ساخت. اولاً، نشان داده شد که با افزایش حجم داده‌های آموزشی از ۵۰۰ به ۵۰۰۰ نمونه، مقدار بهینه k از ۱ به ۱۰ افزایش یافت. این امر تأیید می‌کند که با وجود داده‌های بیشتر، مدل قادر است از اطلاعات همسایه‌های بیشتری برای ایجاد یک مرز تصمیم‌گیری قوی‌تر و با قابلیت تعمیم بالاتر بهره‌برد.

ثانیاً، این افزایش در حجم داده و انتخاب صحیح هایپرپارامتر، منجر به بهبود مستقیم عملکرد نهایی مدل گردید. دقت طبقه‌بند بر روی مجموعه داده تست، از ۲۶.۰٪ در آزمایش با داده‌های کوچک، به ۲۸.۲٪ در آزمایش نهایی افزایش یافت. این نتیجه، ضمن نشان دادن کارایی الگوریتم kNN ، بر اهمیت حیاتی حجم داده و فرآیند بهینه‌سازی هایپرپارامتر در پروژه‌های یادگیری ماشین تأکید می‌کند. در مجموع، این پروژه با موفقیت به اهداف خود در پیاده‌سازی، تحلیل و ارزیابی یک طبقه‌بند استاندارد دست یافت.

Surname: Mirzajani	Name: Amirreza
Title: Performance Evaluation of the k-Nearest Neighbor Classifier for Image Classification Using Cross-Validation	
Supervisor: Dr. M. Shoaran	
Degree: Master of Science	Major: Mechanical Engineering Field: Applied Design
University: University of Tabriz	Faculty: Mechanical Engineering
Pages: ۱۳	
Keywords: k-Nearest Neighbor, Image Classification, CIFAR-۱۰, Machine Learning, Cross-Validation, Hyperparameter Tuning.	
Abstract: Image classification is a central problem in the field of computer vision. In this study, the non-parametric k-Nearest Neighbor (kNN) algorithm is implemented and evaluated for the classification of the standard CIFAR-۱۰ dataset. The primary objective of this project is to analyze the classifier's performance and investigate the impact of training data size on the optimal selection of the hyperparameter k. To this end, experiments were conducted first on a small subset of ۵۰۰ training samples and subsequently on a larger set of ۵۰۰۰ training samples. The optimal value for k in each experiment was determined using ۵-Fold Cross-Validation. The results indicate that as the training data size increased, the optimal k shifted from ۱ to ۱۰, suggesting the model's ability to leverage information from more neighbors to achieve a more robust classification. The final model, trained on ۵۰۰۰ samples with the optimal k, achieved a final accuracy of ۲۸,۲% on the test set. This research confirms the efficacy of the kNN classifier and clearly demonstrates the importance of the cross-validation process and the influence of data volume on hyperparameter optimization.	



University of Tabriz

**Faculty of Electrical and Computer Engineering
Department of Computer Engineering**

Title:

Performance Evaluation of the k-Nearest Neighbor Classifier for Image Classification
Using Cross-Validation

Supervisor:

Dr. M. Shoaran

Researcher:

Amirreza Mirzajani

August ۲۰۲۰