



دانشکده مهندسی برق و کامپیوتر
گروه مهندسی کامپیوتر

عنوان:

پیاده‌سازی و بهینه‌سازی یک شبکه عصبی دو لایه برای طبقه‌بندی تصاویر CIFAR-۱۰

استاد محترم:

دکتر مریم شعاران

دانشجو:

امیررضا میرزاجانی اسکویی

مرداد ۱۴۰۴

نام خانوادگی دانشجو: میرزاجانی اسکوئی		نام: امیررضا	
عنوان: پیاده‌سازی و بهینه‌سازی یک شبکه عصبی دو لایه برای طبقه‌بندی تصاویر CIFAR-۱۰			
استاد محترم: دکتر مریم شعاران			
مقطع تحصیلی: کارشناسی ارشد		رشته: مهندسی مکانیک	
دانشگاه: تبریز		گرایش: طراحی کاربردی	
دانشکده: مهندسی مکانیک		تعداد صفحات: ۱۵	
کلیدواژه‌ها: شبکه عصبی کاملاً متصل، طبقه‌بندی تصاویر، تنظیم فرآپارامتر، پس‌انتشار			
چکیده: طبقه‌بندی تصاویر یکی از وظایف بنیادین در حوزه بینایی کامپیوتر است که با ظهور شبکه‌های عصبی عمیق، پیشرفت‌های چشمگیری داشته است. این پژوهش به طراحی، پیاده‌سازی و بهینه‌سازی یک شبکه عصبی کاملاً متصل دو لایه به منظور طبقه‌بندی مجموعه داده استاندارد CIFAR-۱۰ می‌پردازد. معماری شبکه شامل یک لایه پنهان با تابع فعال‌سازی ReLU است که از پایه و بدون اتکا به کتابخانه‌های سطح بالا پیاده‌سازی شده است. فرآیند آموزش مدل با استفاده از تابع هزینه Softmax، الگوریتم بهینه‌سازی کاهش گرادیان تصادفی (SGD) و تکنیک جریمه $L2$ برای جلوگیری از یادگیری بیش از حد، انجام پذیرفته است. نتایج اولیه با فرآپارامترهای پیش‌فرض، عملکرد ضعیفی با دقت حدود ۲۹٪ را نشان داد که حاکی از لزوم بهینه‌سازی سیستماتیک بود. در ادامه، با به کارگیری روش جستجوی تصادفی برای تنظیم فرآپارامترهای کلیدی نظیر نرخ یادگیری، اندازه لایه پنهان و قدرت جریمه، عملکرد مدل به طور قابل توجهی بهبود یافت. مدل بهینه توانست به دقت نهایی ۴۹.۷٪ بر روی مجموعه داده آزمون دست یابد. این پژوهش اهمیت حیاتی تنظیم فرآپارامترها را در موفقیت مدل‌های یادگیری عمیق نشان داده و یک فرآیند کامل از پیاده‌سازی تا ارزیابی یک طبقه‌بند عصبی را به صورت عملی به تصویر می‌کشد.			

۱- مقدمه

در دهه‌های اخیر، یادگیری عمیق و شبکه‌های عصبی به ابزارهای اصلی در حوزه بینایی کامپیوتر و طبقه‌بندی تصاویر^۱ تبدیل شده‌اند. توانایی ماشین‌ها در تشخیص و دسته‌بندی اشیاء در تصاویر، کاربردهای گسترده‌ای از خودروهای خودران گرفته تا تشخیص‌های پزشکی و سیستم‌های امنیتی را ممکن ساخته است. با این حال، درک عمیق مکانیزم‌های داخلی این شبکه‌ها و فرآیند آموزش آن‌ها، نیازمند پیاده‌سازی عملی و از پایه است. هدف اصلی این پروژه، طراحی، پیاده‌سازی و آموزش یک شبکه عصبی کاملاً متصل^۲ با دو لایه به منظور طبقه‌بندی تصاویر از مجموعه داده چالش برانگیز CIFAR-۱۰^۳ است. این مجموعه داده شامل ۶۰,۰۰۰ تصویر رنگی در ۱۰ کلاس مختلف است که به عنوان یک معیار استاندارد برای ارزیابی مدل‌های بینایی کامپیوتر شناخته می‌شود.

این پروژه یک رویکرد عملی را دنبال می‌کند که در آن، ساختار کامل شبکه از پایه پیاده‌سازی می‌شود. این فرآیند شامل مراحل کلیدی انتشار رو به جلو^۴ برای محاسبه امتیازات کلاس‌ها و انتشار رو به عقب^۵ برای محاسبه گرادیان‌ها، بدون اتکا به کتابخانه‌های سطح بالای یادگیری عمیق است. برای بهینه‌سازی مدل، پارامترهای شبکه با استفاده از تابع هزینه Softmax و الگوریتم کاهش گرادیان تصادفی (SGD) آموزش داده می‌شوند و تکنیک جریمه $L2$ نیز به منظور جلوگیری از یادگیری بیش از حد^۶ و افزایش قدرت تعمیم مدل به کار گرفته می‌شود. بخش مهمی از این پروژه به تنظیم فرآیندهای اختصاص دارد که در آن با استفاده از روش جستجوی تصادفی^۷، بهترین مقادیر برای نرخ یادگیری، قدرت جریمه و اندازه لایه پنهان جستجو می‌شود تا عملکرد مدل به حداکثر برسد.

در نهایت، این گزارش فرآیند کامل ساخت، ارزیابی و بهینه‌سازی شبکه را مستند کرده و با تحلیل نتایج به دست آمده، به درک عمیق‌تری از تأثیر فرآیندهای مختلف بر عملکرد نهایی یک مدل یادگیری عمیق دست می‌یابد.

۲- روش شناسی

در این بخش، متدولوژی به کار گرفته شده برای توسعه و ارزیابی طبقه‌بند شبکه عصبی، از جمله آماده‌سازی داده‌ها، معماری مدل، تابع هزینه و استراتژی بهینه‌سازی، به تفصیل تشریح می‌گردد.

۲-۱ مجموعه داده CIFAR-۱۰ و پیش‌پردازش

مجموعه داده CIFAR-۱۰ یکی از دیتاست‌های استاندارد و پرکاربرد در حوزه بینایی ماشین برای ارزیابی الگوریتم‌های طبقه‌بندی تصاویر است. این مجموعه داده شامل ۶۰,۰۰۰ تصویر رنگی با ابعاد کوچک 32×32 پیکسل می‌باشد. این تصاویر به ۱۰ کلاس مجزا تقسیم‌بندی شده‌اند که هر کلاس شامل ۶,۰۰۰ تصویر است.

^۱ Image Classification

^۲ Fully-Connected

^۳ Forward Pass


^۴ Backward Pass

^۵ Overfitting

^۶ Random Search

کلاس‌ها عبارتند از: هواپیما، اتومبیل، پرنده، گربه، گوزن، سگ، قورباغه، اسب، کشتی و کامیون. کل مجموعه داده به دو بخش اصلی تقسیم شده است: ۵۰,۰۰۰ تصویر برای مجموعه آموزشی و ۱۰,۰۰۰ تصویر برای مجموعه تست^۱ که امکان آموزش و ارزیابی مدل را فراهم می‌آورد.

پس از معرفی مشخصات کلی مجموعه داده CIFAR-۱۰، در شکل ۱ نمونه‌هایی از تصاویر موجود در هر یک از ده کلاس نمایش داده شده است. همانطور که مشاهده می‌شود، این تصاویر با ابعاد کوچک 32×32 پیکسل، چالش‌های قابل توجهی را برای طبقه‌بندی به همراه دارند. تنوع بالا در زاویه دید، شرایط نوری، پس‌زمینه و موقعیت اشیاء در تصاویر، پیچیدگی مسئله را افزایش می‌دهد.



شکل ۱- نمونه تصاویر از مجموعه داده CIFAR-۱۰

جهت انجام فرآیندهای آموزش و ارزیابی، داده‌ها به سه زیرمجموعه مجزا تفکیک شدند: مجموعه آموزش (Training Set) شامل ۴۹,۰۰۰ تصویر، مجموعه اعتبارسنجی (Validation Set) شامل ۱,۰۰۰ تصویر، و مجموعه آزمون (Test Set) شامل ۱,۰۰۰ تصویر. مجموعه اعتبارسنجی نقشی کلیدی در فرآیند تنظیم فرآپارامترها ایفا می‌کند، در حالی که مجموعه آزمون صرفاً برای ارزیابی نهایی بهترین مدل انتخاب‌شده به کار می‌رود.

۲-۲ پیش‌پردازش داده‌ها^۱

به منظور آماده‌سازی داده‌ها برای ورود به شبکه، دو مرحله پیش‌پردازش اعمال گردید:

۱-۲-۲ برداری‌سازی^۲

هر تصویر، که در ابتدا به صورت یک تانسور $32 \times 32 \times 3$ (ارتفاع $\times$ عرض $\times$ کانال‌های رنگی RGB) نمایش داده می‌شد، به یک بردار ویژگی تک‌بعدی با ابعاد $D=3072$ تبدیل گردید. این فرآیند، که به آن "Flattening" نیز گفته می‌شود، برای انطباق با ساختار ورودی لایه‌های تمام-متصل ضروری است.

۲-۲-۲ نرمال‌سازی با مرکزیت صفر^۳

به منظور استانداردسازی توزیع مقادیر پیکسل‌ها، یک تصویر میانگین از کل مجموعه آموزش محاسبه شد. سپس این تصویر میانگین از تمامی تصاویر موجود در مجموعه‌های آموزش، اعتبارسنجی و آزمون کسر گردید. این تکنیک به حذف بایاس‌های ناشی از شرایط نوری مشترک در تصاویر کمک کرده و فرآیند همگرایی الگوریتم بهینه‌سازی را تسریع می‌بخشد.

۳-۲ معماری مدل: شبکه عصبی دو لایه

مدل پیاده‌سازی شده یک شبکه عصبی پیش‌خور^۴ با یک لایه پنهان است. معماری این شبکه را می‌توان به صورت ریاضی به شرح زیر فرموله کرد:

$$f(x) = \max(0, XW_1 + b_1)W_2 + b_2 \quad (1-2)$$

که در آن $X \in R^{N \times D}$ ماتریس ورودی است و شامل N نمونه با D ویژگی می‌باشد.

✓ لایه پنهان (لایه ۱)

این لایه ابتدا یک تبدیل آفین^۵ روی ورودی انجام می‌دهد:

$$Z = XW_1 + b_1 \quad (2-2)$$

- $W_1 \in R^{D \times H}$: ماتریس وزن‌های لایه اول

- $b_1 \in R^{1 \times H}$: بردار بایاس لایه اول

- H : تعداد نوروں‌های لایه پنهان

خروجی این تبدیل از تابع فعال‌سازی ReLU^۶ عبور می‌کند:

$$h = \text{ReLU}(Z) = \max(0, Z) \quad (3-2)$$

این تابع غیرخطی، تمام مقادیر منفی را صفر می‌کند و غیرخطی بودن مدل را تضمین می‌کند.

✓ لایه خروجی (لایه ۲)

^۱ Data Preprocessing

^۲ Vectorization

^۳ Zero-centering

^۴ Feedforward

^۵ Affine Transformation

^۶ Rectified Linear Unit

نمایش فعال شده لایه پنهان h مجدداً از طریق یک تبدیل آفین دیگر عبور می کند:

$$S = hW_2 + b_2 \quad (۴-۲)$$

- $W_2 \in R^{H \times C}$: ماتریس وزن های لایه خروجی

- $b_2 \in R^{1 \times C}$: بردار بایاس لایه خروجی

- C : بعد فضای خروجی

خروجی نهایی شامل امتیازهای خام^۱ هر نمونه بعد از عبور از دو لایه است.

۳-۲ تابع هزینه و بهینه سازی

برای آموزش پارامترهای شبکه $\theta = \{W_1, b_1, W_2, b_2\}$ از تابع هزینه Cross-Entropy به همراه طبقه بند Softmax استفاده شد. تابع Softmax امتیازهای خام خروجی شبکه $S \in \mathbb{R}^{N \times C}$ را به یک توزیع احتمال معتبر روی کلاس ها تبدیل می کند:

$$P(y = k | x_i) = \frac{e^{S_{i,y_i}}}{\sum_{j=1}^C e^{S_{i,j}}} \quad (۴-۲)$$

که در آن $P(y = k | x_i)$ احتمال تعلق نمونه i به کلاس k را نشان می دهد.

۱-۳-۲ تابع هزینه Cross-Entropy

برای یک نمونه، تابع هزینه Cross-Entropy به صورت لگاریتم منفی احتمال پیش بینی شده کلاس صحیح تعریف می شود:

$$\ell(x_i, y_i; \theta) = -\log P(y = y_i | x_i) = \frac{e^{S_{i,y_i}}}{\sum_{j=1}^C e^{S_{i,j}}} \quad (۵-۲)$$

برای یک مینی بچ شامل N نمونه، میانگین این هزینه محاسبه شده و با جریمه $L2$ روی وزن ها ترکیب می شود تا از بیش برآزش جلوگیری شود:

$$L(\theta) = \frac{1}{N} \sum_{i=1}^N \ell(x_i, y_i; \theta) + \frac{\lambda}{2} (\|W_1\|_F^2 + \|W_2\|_F^2) \quad (۶-۲)$$

که در آن:

λ ضریب منظم سازی است که شدت جریمه را تعیین می کند.

$\| \cdot \|_F$ نرم فروبنیوس (جمع مربعات عناصر ماتریس) را نشان می دهد.

عبارت $L2$ با جریمه کردن وزن های بزرگ، پیچیدگی مدل را کاهش داده و از بیش برآزش جلوگیری می کند.

۲-۳-۲ بهینه سازی با Mini-Batch Stochastic Gradient Descent

^۱ Logits

تابع هزینه $L(\theta)$ با استفاده از کاهش گرادیان تصادفی مینی‌بیچ (SGD) به حداقل می‌رسد. در هر مرحله، گرادیان هزینه نسبت به تمام پارامترها با استفاده از پس‌انتشار^۱ محاسبه می‌شود:

$$\nabla_{\theta} L$$

سپس پارامترها در جهت مخالف گرادیان به‌روزرسانی می‌شوند:

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L$$

که در آن:

- η : نرخ یادگیری است که اندازه گام هر به‌روزرسانی را کنترل می‌کند.

- (W_1, b_1, W_2, b_2) : نماینده هر پارامتر قابل آموزش است.

برای بهبود همگرایی و پایداری آموزش، برنامه کاهش نرخ یادگیری^۲ نیز اعمال شد، به طوری که پس از هر دوره^۳ نرخ یادگیری در یک ضریب ثابت ضرب می‌شود:

$$\eta_{\text{new}} = \eta_{\text{old}} \cdot (\text{decay factor}), \quad 0 < \text{decay factor} < 1 \quad (7-2)$$

این کار باعث می‌شود در ابتدای آموزش گام‌های بزرگتری برداشته شود و به تدریج هنگام نزدیک شدن به مینیمم، گام‌ها کوچک‌تر و دقیق‌تر باشند.

۳- نتایج

فرآیند آموزش شبکه در دو مرحله انجام شد: ابتدا یک آزمایش اولیه با داده‌های ساختگی (Toy Data) برای اطمینان از صحت پیاده‌سازی انجام گرفت و سپس مدل بر روی مجموعه داده کامل CIFAR-۱۰ با فرآپارامترهای پیش‌فرض آموزش داده شد.


۳-۱ آموزش بر روی داده‌های ساختگی

برای صحت‌سنجی اولیه پیاده‌سازی، شبکه بر روی یک مجموعه داده کوچک و ساختگی با ۱۰۰ تکرار آموزش داده شد. همانطور که در نمودار شکل ۲ مشاهده می‌شود، هزینه آموزش (Training Loss) به سرعت کاهش یافته و به نزدیک صفر همگرا می‌شود. این امر نشان‌دهنده صحت عملکرد الگوریتم بهینه‌سازی و پیاده‌سازی صحیح مراحل پس‌انتشار است.

^۱ Backpropagation

^۲ Learning Rate Decay

^۳ Epoch



شکل ۲- تاریخچه هزینه آموزش بر روی داده‌های ساختگی

پس از اطمینان از صحت کد، شبکه با فرآپارامترهای پیش فرض بر روی مجموعه داده CIFAR-۱۰ آموزش داده شد. این پارامترها عبارت بودند از:


✓ اندازه لایه پنهان^۱: ۵۰

✓ نرخ یادگیری^۲: $1e-4$

✓ قدرت جریمه^۳: ۰.۲۵

✓ تعداد تکرارها: ۱۰۰۰

نتایج به دست آمده از این آموزش اولیه در نمودارها و تصویر زیر قابل مشاهده است.




شکل ۳- تاریخچه هزینه و دقت طبقه‌بندی در آموزش اولیه

^۱ hidden size

^۲ learning_rate

^۳ Learning rate



شکل ۴- مصورسازی وزن‌های لایه اول پس از آموزش اولیه

با بررسی نتایج فوق، می‌توان چندین مشکل اساسی را در عملکرد مدل تشخیص داد:

- همگرایی کند و هزینه بالا

نمودار بالای شکل ۳ نشان می‌دهد که هزینه (Loss) با شیب بسیار ملایم و تقریباً خطی در حال کاهش است و پس از ۱۰۰۰ تکرار هنوز به مقدار بالایی (حدود ۲.۰) رسیده است. این رفتار معمولاً نشان‌دهنده پایین بودن بیش از حد نرخ یادگیری (learning rate) است. مدل با گام‌های بسیار کوچکی در حال یادگیری است و به زمان بسیار بیشتری برای همگرایی نیاز دارد.

- دقت پایین و یادگیری ناقص (Underfitting)

نمودار پایین شکل ۳، دقت طبقه‌بندی را بر روی داده‌های آموزش (train) و اعتبارسنجی (val) نشان می‌دهد. دقت نهایی بر روی مجموعه اعتبارسنجی حدود ۲۹٪ است که عملکرد بسیار ضعیفی محسوب می‌شود. نکته مهم‌تر، عدم وجود فاصله معنادار بین منحنی دقت آموزش و اعتبارسنجی است. این پدیده نشان می‌دهد که مدل دچار یادگیری ناقص (Underfitting) شده است؛ یعنی ظرفیت مدل به قدری پایین است که حتی قادر به یادگیری کامل الگوهای موجود در داده‌های آموزشی نیز نمی‌باشد. این مشکل به احتمال زیاد ناشی از کوچک بودن اندازه لایه پنهان است.

- عدم یادگیری ویژگی‌های معنادار

شکل ۴، وزن‌های لایه اول (W_1) را به صورت تصویر نمایش می‌دهد. همانطور که مشاهده می‌شود، این وزن‌ها کاملاً نویزی و تصادفی به نظر می‌رسند و هیچ ساختار بصری معناداری (مانند لبه‌ها، رنگ‌ها یا الگوهای ساده)

در آن‌ها قابل تشخیص نیست. این موضوع تأیید می‌کند که لایه اول شبکه نتوانسته است هیچ ویژگی پایه‌ای و مفیدی را از تصاویر ورودی استخراج کند.

نتایج به دست آمده به وضوح نشان می‌دهند که هایپرپارامترهای پیش‌فرض مناسب نیستند. مدل از ظرفیت پایین و نرخ یادگیری بسیار کند رنج می‌برد. بنابراین، برای بهبود عملکرد، انجام یک فرآیند تنظیم فرایارامتر^۱ سیستماتیک ضروری است.

۲-۳ استراتژی تنظیم فرایارامترها و نتایج نهایی

با توجه به نتایج ضعیف آموزش اولیه که حاکی از یادگیری ناقص و نرخ یادگیری بسیار پایین بود، یک فرآیند جستجوی تصادفی^۲ سیستماتیک برای یافتن ترکیبی بهینه از فرایارامترها به کار گرفته شد. بازه‌های جستجو بر اساس تحلیل‌های زیر انتخاب شدند:

✓ نرخ یادگیری (Learning Rate): از آنجایی که نرخ $1e-4$ بسیار کند بود، بازه جستجو به سمت مقادیر بزرگتر سوق داده شد تا همگرایی سریع‌تری حاصل شود. بازه پیشنهادی بین $1e-4$ و $1e-3$ در مقیاس لگاریتمی است. این بازه به مدل اجازه می‌دهد گام‌های بزرگتری برای به‌روزرسانی وزن‌ها بردارد.

✓ اندازه لایه پنهان (Hidden Size): برای مقابله با ظرفیت پایین مدل و مشکل Underfitting، تعداد نوروهای لایه پنهان به طور قابل توجهی افزایش یافت. بازه جستجو بین ۷۵ تا ۲۰۰ نرون انتخاب شد تا مدل‌های با ظرفیت بالاتر نیز مورد آزمایش قرار گیرند.

✓ قدرت جریمه (Regularization Strength): از آنجا که مدل اولیه دچار Underfitting بود، نیازی به جریمه قوی وجود نداشت. بنابراین، بازه جستجو طوری انتخاب شد که مقادیر کوچک‌تر را نیز پوشش دهد تا از محدود شدن بی‌مورد ظرفیت مدل جلوگیری شود.

✓ تعداد تکرارها (Number of Iterations): تعداد مراحل آموزش از ۱۰۰۰ به ۱۵۰۰ افزایش یافت تا مدل زمان کافی برای همگرایی با نرخ‌های یادگیری بالاتر را داشته باشد.

این پارامترها در یک حلقه جستجوی تصادفی با ۲۰ تلاش مورد آزمایش قرار گرفتند. پس از اجرای فرآیند تنظیم، بهترین مدل یافت‌شده توانست به دقت 50.6% بر روی مجموعه اعتبارسنجی دست یابد. پارامترهای این مدل بهینه عبارت بودند از:

○ نرخ یادگیری: $8.77e-4$

^۱ Hyperparameter Tuning

^۲ Random Search

○ قدرت جریمه: $4.41e-2$

○ اندازه لایه پنهان: ۹۹

این مدل بهینه سپس بر روی مجموعه آزمون (Test Set) که تا به حال در هیچ مرحله‌ای از آموزش دیده نشده بود، ارزیابی شد و به دقت نهایی 49.7% دست یافت. این نتیجه به طور چشمگیری بهتر از دقت 29% مدل اولیه است و نشان‌دهنده موفقیت فرآیند تنظیم فرآپارامترها می‌باشد.

در جدول ۱ با بررسی ۲۰ آزمایش مختلف، می‌توانیم نتیجه‌گیری کنیم که چه چیزی موثر بوده و چه چیزی نه.

جدول ۱- نتایج حاصل از تنظیم هایپارامترها در هر آزمایش

شماره آزمایش	نرخ یادگیری	قدرت جریمه	تعداد لایه پنهان	دقت
۱	$8.798571e-04$	$1.094756e-01$	۷۹	0.506000
۲	$1.270061e-04$	$9.518128e-01$	۱۰۳	0.364000
۳	$1.272675e-04$	$5.762571e-01$	۵۲	0.368000
۴	$3.144615e-04$	$6.689767e-01$	۱۳۵	0.456000
۵	$6.381115e-04$	$6.844909e-02$	۸۴	0.485000
۶	$3.931893e-04$	$3.696605e-01$	۱۴۳	0.471000
۷	$6.232882e-04$	$1.953554e-01$	۹۵	0.471000
۸	$3.345319e-04$	$2.760634e-02$	۱۰۷	0.448000
۹	$1.294578e-04$	$2.133663e-01$	۱۲۲	0.371000
۱۰	$5.226623e-04$	$1.491806e-02$	۱۱۲	0.480000
۱۱	$1.523605e-04$	$4.913458e-01$	۶۵	0.380000
۱۲	$2.265654e-04$	$5.372668e-02$	۱۴۰	0.424000
۱۳	$1.796466e-04$	$4.086781e-02$	۱۰۸	0.403000
۱۴	$2.241618e-04$	$4.167139e-01$	۱۴۸	0.418000
۱۵	$7.348929e-04$	$2.260770e-02$	۵۰	0.469000
۱۶	$1.588629e-04$	$3.698530e-01$	۹۴	0.469000
۱۷	$5.292552e-04$	$3.698530e-01$	۱۲۲	0.477000
۱۸	$3.092246e-04$	$1.848375e-01$	۱۰۲	0.444000
۱۹	$8.770257e-04$	$4.415998e-02$	۹۹	0.506000
۲۰	$1.951000e-04$	$5.218464e-02$	۶۷	0.397000

- نتایج کلی به دست آمده به شرح زیر می‌باشد:

• مهم‌ترین عامل، نرخ یادگیری بود.

بهترین مدل‌ها همگی نرخ یادگیری بالایی (بیشتر از $4e-5$) دارند. این فرضیه اولیه شما را تأیید می‌کند: نرخ یادگیری پیش‌فرض بسیار پایین بود و مدل به اندازه کافی سریع یاد نمی‌گرفت و بدترین نتایج همگی نرخ

یادگیری بسیار پایینی دارند. مهم نیست اندازه لایه پنهان چقدر بزرگ یا قدرت جریمه چقدر قوی باشد؛ اگر نرخ یادگیری خیلی کم باشد، مدل به سادگی یاد نمی‌گیرد.

- قدرت جریمه باید متعادل باشد.

با نگاهی به بهترین نتایج، می‌بینیم که قدرت جریمه نسبتاً پایین است (معمولاً زیر ۰.۲). در بدترین نتایج مانند آزمایش ۲، قدرت جریمه بسیار بالاست (۰.۹۵). یک جریمه‌ی اینقدر قوی، مدل را خفه می‌کند و اجازه نمی‌دهد الگوهای پیچیده را یاد بگیرد، به خصوص وقتی با نرخ یادگیری پایین ترکیب شود.

نتیجه‌گیری: مدل اولیه دچار یادگیری ناقص (underfitting) بود، نه یادگیری بیش از حد (overfitting). بنابراین، نیازی به جریمه قوی نداشت. یک جریمه کم یا متوسط برای جلوگیری از overfitting کافی است بدون اینکه ظرفیت یادگیری مدل را محدود کند.


- اندازه لایه پنهان مهم است، اما نه به اندازه نرخ یادگیری

بهترین مدل‌ها اندازه‌های لایه پنهان متفاوتی دارند (۷۹، ۹۹، ۸۴، ۱۱۲). یک اندازه کامل و مشخص وجود ندارد.

با این حال، قابل توجه است که اندازه‌های خیلی کوچک مانند (آزمایش ۳ با تعداد لایه ۵۲) عملکرد خوبی ندارند و اندازه‌های خیلی بزرگ (آزمایش ۱۴ با تعداد لایه ۱۴۸) نیز اگر سایر پارامترها درست نباشند، نتیجه عالی را تضمین نمی‌کنند.

نتیجه‌گیری: افزایش ظرفیت مدل (اندازه لایه پنهان) ایده خوبی بود، اما موفقیت بیشتر به پیدا کردن نرخ یادگیری مناسب بستگی داشت. به نظر می‌رسد یک اندازه بین ۸۰ تا ۱۲۰ نقطه تعادل خوبی است.

با توجه به هایپرپارامترهای تنظیم شده، نتایج حاصل پس از بهینه‌سازی شبکه به صورت زیر در شکل ۵ و ۶ مشخص گشته است.



شکل ۵- تاریخچه هزینه و دقت طبقه‌بندی برای مدل بهینه



شکل ۶- مصورسازی وزن‌های لایه اول پس از فرآیند تنظیم فرآپارامترها

نتیجه گیری

در این پروژه، یک شبکه عصبی کاملاً متصل دو لایه با موفقیت از پایه پیاده‌سازی، آموزش و بهینه‌سازی گردید تا قادر به طبقه‌بندی تصاویر از مجموعه داده CIFAR-۱۰ باشد. این فرآیند، درک عمیقی از چالش‌های

عملی در حوزه یادگیری عمیق، از صحت‌سنجی پیاده‌سازی گرفته تا تأثیر حیاتی فراپارامترها بر عملکرد نهایی مدل، فراهم آورد.

نتایج اولیه با استفاده از فراپارامترهای پیش‌فرض، عملکردی ضعیف با دقت حدود ۲۹٪ را نشان داد که ناشی از پدیده یادگیری ناقص، نرخ یادگیری بسیار پایین و ظرفیت ناکافی مدل بود. این موضوع اهمیت یک رویکرد سیستماتیک برای بهینه‌سازی را آشکار ساخت. با به کارگیری روش جستجوی تصادفی، تأثیر فراپارامترهای کلیدی شامل نرخ یادگیری، اندازه لایه پنهان و قدرت جریمه به طور گسترده مورد بررسی قرار گرفت.

تحلیل نتایج این جستجو نشان داد که نرخ یادگیری مهم‌ترین عامل در موفقیت آموزش بوده و انتخاب مقادیر مناسب برای آن، به تنهایی قادر به بهبود چشمگیر عملکرد است. مدل بهینه، با بهره‌گیری از نرخ یادگیری بالاتر، ظرفیت بیشتر (لایه پنهان بزرگتر) و جریمه متعادل، توانست به دقت نهایی ۴۹.۷٪ بر روی مجموعه داده آزمون دست یابد. این بهبود قابل توجه، که در نمودارهای همگرایی سریع‌تر و مصورسازی وزن‌های معنادار لایه اول نیز مشهود بود، موفقیت استراتژی بهینه‌سازی را تأیید می‌کند.

در نهایت، اگرچه دقت به دست آمده برای یک شبکه تمام-متصل ساده قابل قبول است، اما با مدل‌های پیشرفته‌تر در حوزه بینایی کامپیوتر فاصله دارد. این پروژه به وضوح نشان می‌دهد که در حالی که شبکه‌های تمام-متصل قادر به یادگیری الگوها هستند، برای وظایف پیچیده تصویری، معماری‌های تخصصی‌تری مانند شبکه‌های عصبی کانولوشنی (CNNs) که قادر به درک ساختار فضایی تصاویر هستند، ضروری می‌باشند. به عنوان گام‌های بعدی، می‌توان به کارگیری معماری‌های عمیق‌تر، استفاده از بهینه‌سازهای پیشرفته‌تر مانند Adam و پیاده‌سازی تکنیک‌های افزایش داده (Data Augmentation) را برای بهبود بیشتر عملکرد پیشنهاد داد.

Surname: Mirzajani	Name: Amirreza
Title: Implementation and Optimization of a Two-Layer Neural Network for CIFAR-10 Image Classification	
Supervisor: Dr. M. Shoaran	
Degree: Master of Science	Major: Mechanical Engineering Field: Applied Design
University: University of Tabriz	Faculty: Mechanical Engineering
Pages: ۱۵	
Keywords: Fully-Connected Neural Network, Image Classification, CIFAR-10 Dataset, Hyperparameter Tuning, Backpropagation	
Abstract: Image classification is a fundamental task in computer vision that has seen significant advancements with the rise of deep neural networks. This research focuses on the design, implementation, and optimization of a two-layer fully-connected neural network for classifying the standard CIFAR-10 dataset. The network architecture, featuring a hidden layer with a ReLU activation function, was implemented from scratch without relying on high-level libraries. The model's training process was conducted using the Softmax loss function, the Stochastic Gradient Descent (SGD) optimization algorithm, and L₂ regularization to prevent overfitting. Initial results with default hyperparameters yielded poor performance with an accuracy of approximately ۲۹%, highlighting the need for systematic optimization. Subsequently, by employing a Random Search method to tune key hyperparameters such as learning rate, hidden layer size, and regularization strength, the model's performance was significantly improved. The optimized model achieved a final accuracy of ۴۹,۷% on the test set. This study demonstrates the critical importance of hyperparameter tuning in the success of deep learning models and practically illustrates the complete pipeline of implementing and evaluating a neural classifier.	



University of Tabriz

**Faculty of Electrical and Computer Engineering
Department of Computer Engineering**

Title:

Implementation and Optimization of a Two-Layer Neural Network for CIFAR-۱۰
Image Classification

Professor:

Dr. M. Shoaran

Researcher:

Amirreza Mirzajani

August ۲۰۲۰